

Especificação de Dados e Fluxo de Pipeline

Grupo 3 - Data Science

Nome: Aline de Souza Fragoso

Nome: Grazielly Zambello Fuzato

Nome: João Vitor Toledo da Silva

Nome: Pedro de Freitas da Silva

1. Fontes de Dados Brutos

1.1 Vendas (Excel)

Variável	Tipo de Dado
id_venda	Inteiro
data_hora	Datetime
id_aluno	String
id_produto	String
quantidade	Inteiro
valor_unitario	Decimal
valor_total	Decimal
forma_pagamento	String

Frequência de geração: Contínua (a cada venda), consolidada em planilha diária/semanal

Inconsistências possíveis:

- Valores nulos em forma_pagamento;
- Valor_total divergente do cálculo;
- Duplicidade de id_venda;
- Datas em formatos distintos Ex: dd/mm/aaaa vs. aaaa-mm-dd;
- Preços negativos.

1.2 Devedores (Excel)

Variável	Tipo de Dado
id_devedor	Inteiro
id_aluno	Inteiro
data_divida	Date
valor_devido	Decimal
status	String
data_quitacao	Date

Frequência de geração: Atualização diária/semanal (registro manual)

Inconsistências possíveis:

- Id_aluno não localizado na base de alunos;
- Status desatualizado;
- Datas de quitação anteriores à data da dívida;
- Múltiplos registros para o mesmo débito.

1.3 Cardápio de Produtos(Excel)

Variável	Tipo de Dado
id_produto	Inteiro
nome_produto	String
categoria	String
preco_venda	Decimal
custo_unitario	Decimal

Frequência de geração: baixa (atualizado quando há reajuste de preço ou mudança de cardápio)

Inconsistências possíveis:

- Produto referenciado em vendas mas ausente do cardápio vigente;
- Preço desatualizado em relação ao índice de inflação;
- Custo_unitario ausente.

1.4 Perdas/Desperdício (Excel)

Variável	Tipo de Dado
id_perda	Inteiro
data	Date
id_produto	Inteiro
quantidade	Inteiro
motivo	String
valor_prejuizo	Decimal

Frequência de geração: diária (registro manual ao final do expediente)

Inconsistências possíveis:

- Motivo não preenchido;
- Produto sem correspondência no cardápio;
- Quantidade zerada ou negativa.

1.5 Calendário Escolar(Json)

Variável	Tipo de Dado
data	Date
tipo_dia	String (categórico)
descricao	String
turno_letivo	String (categórico)

Frequência de geração: estática, publicada no início do ano/semestre, com atualizações pontuais

Inconsistências possíveis:

- Conflito entre datas marcadas como letivas e feriados nacionais;
- Ausência de atualização após alteração de calendário (greve, reposição).

1.6 Clima e Temperatura do Dia (JSON)

Variável	Tipo de Dado
data	Date
temperatura_media	Decimal
temperatura_max	Decimal
condicao	String (categórico)
precipitacao_mm	Decimal

Frequência de geração: diária, obtida via requisição automatizada

Inconsistências possíveis:

- Falha de requisição gerando dados ausentes;
- Granularidade diferente;
- Fuso horário divergente.

1.7 Turmas e Alunos (JSON)

Variável	Tipo de Dado
turma	String
ano_letivo	Inteiro
turno	String
id_aluno	Inteiro
nome	String
data_nascimento	Date
restricao_alimentar	String

Frequência de geração: baixa (início de ano letivo, com atualizações por transferência/matricula)

Inconsistências possíveis:

- Id_aluno em formato diferente do usado nas vendas/devedores;
- Campos aninhados ausentes;
- Nomes duplicados entre alunos diferentes.

1.8 Índice de Preços / Inflação

Variável	Tipo de Dado
mes_referencia	Date (ano-mês)
indice_inflacao	Decimal
categoria_produto	String (categórico)

Frequência de geração: mensal

Inconsistências possíveis:

- Defasagem de publicação;
- Categoria não compatível com as categorias do cardápio.

2. Fluxo Inicial do Pipeline

2.1 Visão Geral

Geração → Armazenamento (Bronze) → Tratamento (Silver) → Disponibilização (Gold)

- Geração: Vendas, Devedores, Cardápio, Perdas, Calendário Escolar, Clima (API), Turmas/Alunos (JSON), Frequência (CSV externo/SED), Índice de Inflação (API)
- Armazenamento — Bronze: Data Lake / Storage Bruto, recebendo todas as fontes sem alteração
- Tratamento — Silver: Padronização de schema → Deduplicação → Mapeamento de chaves (id_aluno x cod_aluno) → Tratamento de nulos/outliers → Conciliação temporal (defasagens)
- Disponibilização — Gold: Tabelas agregadas → Views para BI/EDA → Modelos estatísticos

2.2 Etapa 1 — Geração dos Dados

- Fontes internas (vendas, devedores, cardápio, perdas) são geradas manual/operacionalmente pela cantina, em planilhas Excel.
- Fontes acadêmicas (turmas/alunos) são simuladas como exportações de um sistema de gestão escolar externo, em JSON e CSV com schema próprio.
- Fontes externas (clima, inflação) são obtidas via chamadas de API, com frequência diária e mensal respectivamente.

- Cada fonte carrega sua própria frequência e formato original, sem padronização prévia — reproduzindo um cenário real de heterogeneidade.

2.3 Etapa 2 — Armazenamento (Camada Bronze)

- Todos os arquivos brutos (Excel, JSON, CSV) são armazenados sem alteração em um repositório central (data lake simulado), preservando a fonte original para fins de auditoria e rastreabilidade.
- Organização sugerida por pasta/data de ingestão: /bronze/vendas/, /bronze/frequencia/, etc.

2.4 Etapa 3 — Tratamento (Camada Silver)

Principais tarefas de tratamento a serem aplicadas:

- Padronização de schema: unificar nomes de colunas e tipos de dados entre fontes com nomenclaturas diferentes (ex.: cod_aluno do SED vs. id_aluno interno).
- Deduplicação: remoção de registros duplicados (vendas, dívidas).
- Mapeamento de chaves: criação de tabela de-para entre identificadores de alunos usados em sistemas diferentes.
- Tratamento de nulos e outliers: valores ausentes em forma de pagamento, preços negativos, quantidades inconsistentes.
- Conciliação temporal: ajuste de defasagens (ex.: frequência disponibilizada em D+1, inflação disponibilizada com atraso mensal).
- Enriquecimento cruzado: junção de vendas com clima do dia e cardápio vigente.

2.5 Etapa 4 — Disponibilização (Camada Gold)

Geração de tabelas agregadas e views prontas para consumo analítico, por exemplo:

- Venda por turma/mês
- Inadimplência por período/turma
- Relação clima × volume de vendas
- Desperdício por categoria de produto
- turmas × dias de pico de venda

Essas tabelas alimentam diretamente as etapas de Análise Exploratória de Dados (EDA), Probabilidade e Estatística previstas no projeto, além de dashboards de apoio à tomada de decisão.